

# PCA: Метод главных компонент

## Пример 1: моделирование Монте-Карло

Рассмотрим  $n := 3$  признаков в задаче ML. Каждое их сочетание задает выборочное значение вектора в пространстве  $R^3$ .  $\mathbf{x} = (x_0, x_1, x_2) = (x, y, z)$ . Будем считать, что признаки коррелированы, а именно:  $z(x, y) := 0 + 2x - 5y$ .

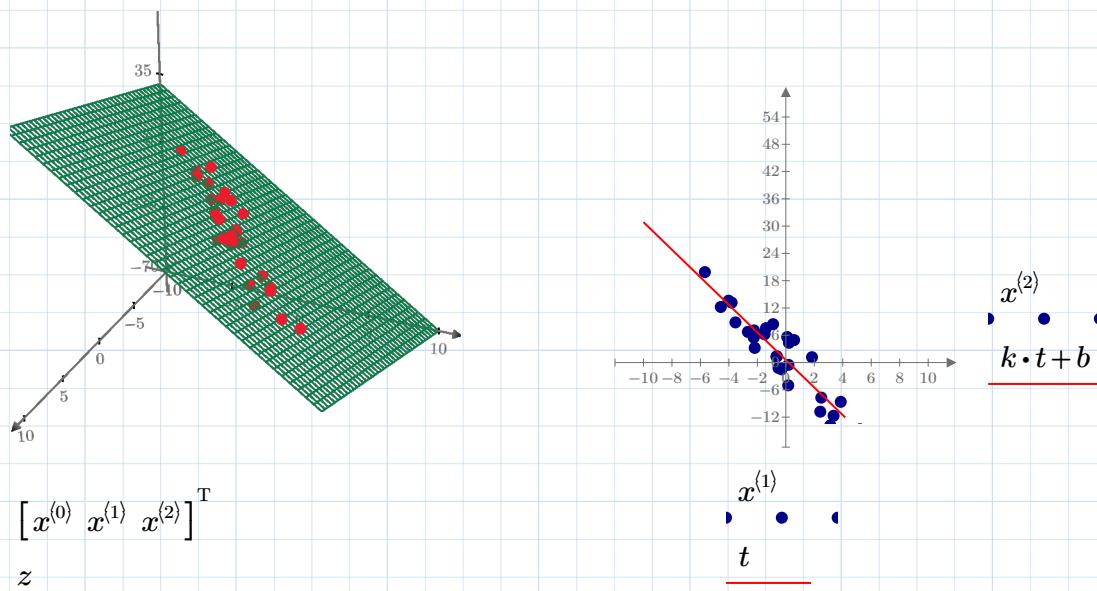
Сгенерируем псевдослучайную выборку объема  $N := 30$ , причем пусть  $x, y$  будут независимыми, а  $z = z(x, y) + \text{шум}$ , интенсивность которого возьмем равной  $\sigma := 10$ .

Т.е. наша выборка = это  $N = 30$  псевдослучайных векторов в пространстве  $R^3$ , которые можно объединить в матрицу  $N \times n$ :

$$x = \begin{bmatrix} -0.592 & 0.167 & -5.012 \\ -0.168 & -1.394 & 7.561 \\ -3.016 & -4.02 & 13.608 \\ 3.411 & 2.491 & -7.716 \\ -1.641 & -2.187 & 3.23 \\ 4.626 & 3.354 & -11.703 \\ \vdots \end{bmatrix}$$

В силу коррелированности, все точки (векторы в  $R^3$ ) расположены вблизи плоскости:  $z(x, y)$

Причем, чем меньше шум  $s = 1$ , тем все точки ближе к плоскости (при нулевом шуме они точно лежат в плоскости):



Мы хотим снизить размерность: найти признаки - комбинацию коррелированных признаков и оставить только их.

## Расчет 1: R<sub>2</sub> --> R<sub>1</sub>

Сначала (для наглядности) можно рассмотреть более простой случай - проекцию пространства R<sub>3</sub>. Новый признак будет задаваться вектором v. Как его найти?

**1-й вариант** - вручную (построить лин.регрессию по МНК):

$$V(K) = \begin{bmatrix} 0.282 \\ -0.959 \end{bmatrix} \quad \text{и ортогональный ему, "лишний" вектор } V2(K) = \begin{bmatrix} -0.959 \\ -0.282 \end{bmatrix}$$

$$V(K) \cdot V2(K) = 0$$

**2-й вариант** - через ковариационную матрицу:

$$\text{cvar}(x^{(1)}, x^{(2)}) = -24.512$$

$$\text{corr}(x^{(1)}, x^{(2)}) = -0.938$$

$$\frac{\text{cvar}(x^{(1)}, x^{(2)})}{\text{stdev}(x^{(1)}) \cdot \text{stdev}(x^{(2)})} = -0.938$$

$$A := \begin{bmatrix} \text{cvar}(x^{(1)}, x^{(1)}) & \text{cvar}(x^{(1)}, x^{(2)}) \\ \text{cvar}(x^{(1)}, x^{(2)}) & \text{cvar}(x^{(2)}, x^{(2)}) \end{bmatrix} = \begin{bmatrix} 8.088 & -24.512 \\ -24.512 & 84.361 \end{bmatrix}$$

Надо посчитать ее с.з. и с.в.. И как раз с.в., имеющий максимальное с.з., будет главным направлением (сравнить результат с вариантом 1):

$$L := \text{eigenvals}(A) = \begin{bmatrix} 91.559 \\ 0.89 \end{bmatrix}$$

$$\text{eigenvec}(A, L_0) = \begin{bmatrix} -0.282 \\ 0.959 \end{bmatrix}$$

$$\text{eigenvec}(A, L_1) = \begin{bmatrix} 0.959 \\ 0.282 \end{bmatrix}$$

$$V(K) = \begin{bmatrix} 0.282 \\ -0.959 \end{bmatrix}$$

$$V2(K) = \begin{bmatrix} -0.959 \\ -0.282 \end{bmatrix}$$

$$\text{eigenvec}(A, L_0) \cdot V(K) = -1$$

$$V(r_{d_0}) = \begin{bmatrix} 0.282 \\ -0.959 \end{bmatrix}$$

$$V2(r_{d_0}) = \begin{bmatrix} -0.959 \\ -0.282 \end{bmatrix}$$

## Расчет 2 - в 3D: R<sub>3</sub> --> R<sub>2</sub>

$$i0 := 0 \dots 2 \quad i1 := 0 \dots 2$$

$$Cov_{i0, i1} := \text{cvar}(x^{(i0)}, x^{(i1)})$$

$$Cov = \begin{bmatrix} 7.863 & 7.373 & -20.705 \\ 7.373 & 8.088 & -24.512 \\ -20.705 & -24.512 & 84.361 \end{bmatrix}$$

$$L := \text{eigenvals}(Cov) = \begin{bmatrix} 96.964 \\ 3.111 \\ 0.237 \end{bmatrix}$$

$$\text{eigenvec}(Cov, L_0) = \begin{bmatrix} -0.239 \\ -0.277 \\ 0.931 \end{bmatrix}$$

$$\|\text{eigenvec}(Cov, L_0)\| = 1$$

$$\text{eigenvec}(Cov, L_1) = \begin{bmatrix} 0.853 \\ 0.398 \\ 0.337 \end{bmatrix}$$

$$\text{eigenvec}(Cov, L_0) \cdot \text{eigenvec}(Cov, L_1) = 0$$

$$\text{eigenvec}(Cov, L_2) = \begin{bmatrix} -0.463 \\ 0.875 \\ 0.141 \end{bmatrix}$$

### Расчет 3 - через SVD

Тот же самый результат (т.е. новый базис) можно получить, если использовать SVD ковариационной матрицы  $Cov = V \cdot S \cdot V^T$ . Сравните с.з. ковариационной матрицы и сингулярные числа S:

$$L = \begin{bmatrix} 96.964 \\ 3.111 \\ 0.237 \end{bmatrix} \quad s := \text{svd}(Cov)_0 = \begin{bmatrix} 96.964 \\ 3.111 \\ 0.237 \end{bmatrix} \quad S := \text{diag}(s) = \begin{bmatrix} 96.964 & 0 & 0 \\ 0 & 3.111 & 0 \\ 0 & 0 & 0.237 \end{bmatrix}$$

и столбцы ортогональной матрицы V с с.в. ковариационной матрицы:

$$U := \text{svd}(Cov)_1 = \begin{bmatrix} -0.239 & -0.853 & 0.463 \\ -0.277 & -0.398 & -0.875 \\ 0.931 & -0.337 & -0.141 \end{bmatrix} \quad \text{eigenvec}(Cov, L_0) = \begin{bmatrix} -0.239 \\ -0.277 \\ 0.931 \end{bmatrix}$$

$$V := \text{svd}(Cov)_2^T = \begin{bmatrix} -0.239 & -0.853 & 0.463 \\ -0.277 & -0.398 & -0.875 \\ 0.931 & -0.337 & -0.141 \end{bmatrix} \quad \text{eigenvec}(Cov, L_1) = \begin{bmatrix} 0.853 \\ 0.398 \\ 0.337 \end{bmatrix}$$

$$V^{-1} = \begin{bmatrix} -0.239 & -0.277 & 0.931 \\ -0.853 & -0.398 & -0.337 \\ 0.463 & -0.875 & -0.141 \end{bmatrix} \quad \text{eigenvec}(Cov, L_2) = \begin{bmatrix} -0.463 \\ 0.875 \\ 0.141 \end{bmatrix}$$

$$V^T = \begin{bmatrix} -0.239 & -0.277 & 0.931 \\ -0.853 & -0.398 & -0.337 \\ 0.463 & -0.875 & -0.141 \end{bmatrix}$$

Таким образом, SVD-разложение ковариационной матрицы задает главные компоненты данных и его можно записать как:

$$V \cdot S \cdot V^T = \begin{bmatrix} 7.863 & 7.373 & -20.705 \\ 7.373 & 8.088 & -24.512 \\ -20.705 & -24.512 & 84.361 \end{bmatrix} \quad Cov = \begin{bmatrix} 7.863 & 7.373 & -20.705 \\ 7.373 & 8.088 & -24.512 \\ -20.705 & -24.512 & 84.361 \end{bmatrix}$$

Нормы матрицы (Фробениуса и евклидова) также можно получить через SVD:

$$\sum_{i=0}^2 \sum_{j=0}^2 Cov_{i,j}^2 = 9.412 \cdot 10^3 \quad \sum s^2 = 9.412 \cdot 10^3$$

$$\text{norme}(Cov) = 97.015 \quad s_0 = 96.964$$

## Расчет 4 - SVD самих данных X

$$s := \text{svd}(x)_0 = \begin{bmatrix} 54.524 \\ 9.728 \\ 2.674 \end{bmatrix} \quad S := \text{diag}(s) = \begin{bmatrix} 54.524 & 0 & 0 \\ 0 & 9.728 & 0 \\ 0 & 0 & 2.674 \end{bmatrix} \quad X = U \cdot S \cdot V^T$$

$$U := \text{svd}(x)_1 \quad V := \text{svd}(x)_2^T = \begin{bmatrix} 0.237 & 0.853 & -0.466 \\ 0.275 & 0.401 & 0.874 \\ -0.932 & 0.335 & 0.139 \end{bmatrix}$$

$$\sum_{i=0}^2 U^{(i)} \cdot s_i \cdot (V^{(i)})^T = \begin{bmatrix} -0.592 & 0.167 & -5.012 \\ -0.168 & -1.394 & 7.561 \\ -3.016 & -4.02 & 13.608 \\ 3.411 & 2.491 & -7.716 \\ -1.641 & -2.187 & 3.23 \\ \vdots & & \end{bmatrix} \quad x = \begin{bmatrix} -0.592 & 0.167 & -5.012 \\ -0.168 & -1.394 & 7.561 \\ -3.016 & -4.02 & 13.608 \\ 3.411 & 2.491 & -7.716 \\ -1.641 & -2.187 & 3.23 \\ 4.626 & 3.354 & -11.703 \\ \vdots & & \end{bmatrix}$$

$$M := 1$$

$$xx := \sum_{i=0}^{M-1} U^{(i)} \cdot s_i \cdot (V^{(i)})^T = \begin{bmatrix} 1.083 & 1.258 & -4.265 \\ -1.768 & -2.052 & 6.96 \\ -3.432 & -3.984 & 13.512 \\ 2.055 & 2.386 & -8.092 \\ -0.947 & -1.099 & 3.727 \\ 3.059 & 3.551 & -12.043 \\ \vdots & & \end{bmatrix}$$

